

Universidad Nacional de San Agustín

Ciencia de la Computación

Optimización medida de MPI

Difusión, topología y multiplicación de matrices

Extensión reproducible del proyecto

<https://github.com/dtamotu/cluster-mpi-96-optimizaciones>

Integrantes:

Paredes Malaga José Carlos
Jheeremy Manuel Alvarez Astete
Jose Alejandro Machaca Muñiz
David Tamo Turpo
Wilson Ramos

Curso:

Computación Paralela y Distribuida

Profesor:

Alvaro Henry Mamani Aliaga

Índice

1. Pregunta y punto de partida	2
2. Diseño de experimentos	2
3. Resultados	3
4. Comparaciones principales	5
5. Interpretación y límites	6
6. Reproducción	7

1. Pregunta y punto de partida

Se investiga si pueden reducirse más los tiempos medidos al multiplicar matrices en un clúster de cuatro computadoras, cada una con 24 núcleos. La batería anterior, preservada en `datos/ampliada/resultados_consolidados.csv`, registró para $N = 3072$ tiempos de 0.547 s con 24 procesos locales, 6.148 s con 96 procesos por Ethernet y 99.945 s con 96 procesos por Wi-Fi. Con 96 procesos, el cálculo local máximo fue 0.104 s por Ethernet y 0.139 s por Wi-Fi; el costo dominante se registró en distribución y espera. Son corridas individuales, no distribuciones estadísticas.

La corrida histórica de 906.351 s con ocho procesos registró 889.744 s en `MPI_Bcast`. No es una repetición de la batería de 96 procesos: también cambiaron ejecutable, algoritmo local, asignación y condiciones de red. La ausencia de la opción explícita `vader` no demuestra que Open MPI enviara tráfico local por TCP; Open MPI 4.x puede escoger memoria compartida por defecto¹.

2. Diseño de experimentos

Cada corrida usa la misma matriz determinista, el núcleo local `tilled` y una sola ejecución MPI a la vez. El script de esta carpeta guarda comando, salida, fecha, versión de Open MPI y contadores TX/RX de cada nodo. Los resultados se identifican por red, procesos, nodos, variante y repetición. El orden cambia de forma determinista entre repeticiones. Las cinco repeticiones permiten describir dispersión, pero no garantizan condiciones de red idénticas.

1. **Uno frente a cuatro nodos.** Se comparan 24 procesos locales y 96 procesos en cuatro nodos, tanto por Ethernet como por Wi-Fi.
2. **Difusión jerárquica explícita.** En `1d-hier`, los líderes de nodo difunden B entre sí y cada líder vuelve a difundirla localmente. `1d` usa una colectiva global. Se miden por separado `Scatterv` y `Bcast`. El cálculo y los datos son los mismos.
3. **Difusión aislada.** Se transmite una matriz de 75.497 MB con 16 procesos: todos en un nodo o cuatro en cada uno de cuatro nodos. Se contrastan la colectiva global, la jerárquica y dos algoritmos solicitados al componente `tuned`: `knomial` y `scatter_allgather`. Las opciones disponibles se verificaron en Open MPI 4.1.6 mediante `mpi_info`.
4. **Distribución 2D.** Se compara el 1D con SUMMA 2D a $P = 64$ y $N = 3072$. El programa 2D actual exige $P = q^2$ y N divisible por q , de modo que 96 procesos no son una comparación válida sin modificar la partición.
5. **Tamaño mayor.** Por Ethernet se miden matrices de $N = 6144$ y $N = 7168$ con 24 y 96 procesos. Esto busca un posible cruce entre uno y cuatro nodos dentro de tamaños compatibles con la memoria por proceso. No se extrapola hasta tamaños que la implementación 1D no puede alojar.
6. **Trapezio asimétrico.** Se corrige la contribución del extremo $f(1)/2$ que faltaba en el programa experimental. Se comparan partición simétrica y ponderada para $n = 10^8$ y 10^{11} , con 24 y 96 procesos, por Ethernet. La ponderación fija asigna peso 1.2658 a los primeros ocho rangos de cada nodo y 1 a los demás; es una hipótesis previa, no una calibración nueva. Los logs guardan error absoluto de la integral, afinidad de rangos y tiempos máximos y mínimos de cálculo.

La cifra de tráfico es la suma de bytes TX de las interfaces de los nodos participantes durante cada ventana, en MB decimales. También se guardan RX y los valores antes/después. Estas cifras pueden

¹<https://www.open-mpi.org/faq/?category=tcp>

incluir SSH, control MPI y tráfico ajeno. No representan por sí solas bytes útiles de una colectiva ni uso total del aire Wi-Fi. Los máximos de fases pueden corresponder a procesos distintos y no se suman para reconstruir el tiempo total.

Para $N = 3072$, una matriz de dobles ocupa $8N^2 = 75.497472$ MB. Si una difusión transmitiera una copia de B hacia cada uno de los tres nodos remotos, la carga útil ideal entre nodos sería $3 \times 75.497472 = 226.492416$ MB. Esta es una referencia de volumen útil, no un contador medido ni una identificación del algoritmo interno de Open MPI.

3. Resultados

Se guardaron 118 intentos, de los cuales 118 terminaron y entregaron una línea de resultado válida.

Tabla 1: Resultados medidos en la batería nueva. Los tiempos son medianas de las corridas válidas; el rango muestra mínimo y máximo. TX suma la transmisión de los nodos participantes.

Red	Prueba	Tamaño	P	Nodos	Variante	Reps.	T med. (s)	Rango (s)	TX (MB)
Ethernet	bcast	3072	16	1	hier	3	0.124	0.117–0.129	0.0
Ethernet	bcast	3072	16	1	world	3	0.116	0.116–0.127	0.0
Ethernet	bcast	3072	16	4	hier	3	2.034	2.030–2.035	238.4
Ethernet	bcast	3072	16	4	tuned–knomial	3	1.977	1.974–1.983	238.4
Ethernet	bcast	3072	16	4	tuned–scatter	3	4.372	4.010–4.374	1032.4
Ethernet	bcast	3072	16	4	world	3	4.294	4.003–4.351	1032.5
Wi-Fi	bcast	3072	16	4	hier	3	30.464	29.791–31.940	228.0
Wi-Fi	bcast	3072	16	4	tuned–knomial	3	29.575	29.354–29.650	228.6
Wi-Fi	bcast	3072	16	4	tuned–scatter	3	134.479	132.263–134.957	1006.5
Wi-Fi	bcast	3072	16	4	world	3	133.043	131.304–133.633	1006.5
Ethernet	matriz	3072	24	1	1d	5	0.649	0.633–0.719	0.0
Ethernet	matriz	3072	24	1	1d–hier	5	0.691	0.677–0.799	0.0
Ethernet	matriz	3072	64	4	1d	3	3.147	3.147–3.148	358.0
Ethernet	matriz	3072	64	4	2d	3	5.492	5.469–5.546	678.1
Ethernet	matriz	3072	96	4	1d	5	6.260	6.233–6.266	755.5
Ethernet	matriz	3072	96	4	1d–hier	5	3.217	3.088–3.288	358.9
Ethernet	matriz	6144	24	1	1d	3	5.279	4.998–7.343	0.6
Ethernet	matriz	6144	96	4	1d	3	25.194	25.065–25.322	3022.4
Ethernet	matriz	7168	24	1	1d	3	7.686	7.561–7.703	0.4
Ethernet	matriz	7168	96	4	1d	3	35.116	35.086–35.130	4113.9
Wi-Fi	matriz	3072	24	1	1d	5	0.666	0.581–0.722	0.0
Wi-Fi	matriz	3072	24	1	1d–hier	5	0.673	0.608–4.769	0.0
Wi-Fi	matriz	3072	64	4	1d	3	51.728	48.975–52.122	343.0
Wi-Fi	matriz	3072	64	4	2d	3	87.314	86.305–87.779	677.7
Wi-Fi	matriz	3072	96	4	1d	5	101.082	100.293–102.991	729.3
Wi-Fi	matriz	3072	96	4	1d–hier	5	51.479	50.817–52.659	342.9
Ethernet	trapecio	10^8	24	1	asimetrico	3	0.004	0.004–0.007	0.0
Ethernet	trapecio	10^8	24	1	simetrico	3	0.007	0.005–0.008	0.0
Ethernet	trapecio	10^8	96	4	asimetrico	3	0.002	0.002–0.002	0.6
Ethernet	trapecio	10^8	96	4	simetrico	3	0.002	0.001–0.006	0.4
Ethernet	trapecio	10^{11}	24	1	asimetrico	3	4.940	4.528–5.153	0.1
Ethernet	trapecio	10^{11}	24	1	simetrico	3	5.183	4.753–5.379	0.0
Ethernet	trapecio	10^{11}	96	4	asimetrico	3	1.046	1.026–1.198	0.5
Ethernet	trapecio	10^{11}	96	4	simetrico	3	1.012	1.004–1.024	0.8




Figura 1: Tiempo del programa completo, mediana y rango de las corridas válidas. La escala vertical es logarítmica.




Figura 2: Difusión aislada entre cuatro nodos. La escala vertical es logarítmica; las barras de error muestran mínimo y máximo.

La columna T corresponde a T_{Total} del programa completo o a T_{Bcast} del microbenchmark. Por tanto, se comparan tiempos solo dentro de cada tipo de prueba. Los logs de matrices conservan además la suma diagonal y una suma ponderada de la matriz final; el microbenchmark comprueba que las huellas de 64 bits de los búferes coinciden entre procesos.

4. Comparaciones principales

En Ethernet, la difusión jerárquica explícita frente a 1D por defecto a $P = 96$ dio un cociente de tiempos 1.95 veces y un cociente de TX agregados 2.11 veces. Un valor mayor que 1 favorece la variante jerárquica. El máximo de la fase Bcast pasó de 5.611 a 2.474 s.

En Wi-Fi, la difusión jerárquica explícita frente a 1D por defecto a $P = 96$ dio un cociente de tiempos 1.96 veces y un cociente de TX agregados 2.13 veces. Un valor mayor que 1 favorece la variante jerárquica. El máximo de la fase Bcast pasó de 88.904 a 40.272 s.




Figura 3: Tiempo de matrices 1D por Ethernet, con uno o cuatro nodos. Los puntos muestran medianas y los extremos de las barras el rango observado.

En Ethernet, 1D frente a SUMMA 2D, ambos con $P = 64$, dio un cociente de tiempos 0.57 veces y un cociente de TX agregados 0.53 veces. Un valor menor que 1 favorece 1D.

En Wi-Fi, 1D frente a SUMMA 2D, ambos con $P = 64$, dio un cociente de tiempos 0.59 veces y un cociente de TX agregados 0.51 veces. Un valor menor que 1 favorece 1D.

En la difusión aislada por Ethernet, la colectiva global frente a la jerárquica dio un cociente de tiempo 2.11 veces y de TX agregado 4.33 veces.

En la difusión aislada por Wi-Fi, la colectiva global frente a la jerárquica dio un cociente de tiempo 4.37 veces y de TX agregado 4.41 veces.

Con 16 procesos y difusión global por Ethernet, cuatro nodos frente a uno dieron un cociente 37.08 veces.

En Ethernet, cuatro nodos con 96 procesos frente a un nodo con 24 procesos dieron un cociente T_{96}/T_{24} de 9.65 veces. Aquí un valor mayor que 1 favorece un nodo.

En Wi-Fi, cuatro nodos con 96 procesos frente a un nodo con 24 procesos dieron un cociente T_{96}/T_{24} de 151.70 veces. Aquí un valor mayor que 1 favorece un nodo.

Para $N = 6144$ por Ethernet, T_{96}/T_{24} fue 4.77 veces.

Para $N = 7168$ por Ethernet, T_{96}/T_{24} fue 4.57 veces.

Trapezio con $n = 10^8$ y $P = 24$: T_{sim}/T_{asim} fue 1.70 veces.

Trapezio con $n = 10^8$ y $P = 96$: T_{sim}/T_{asim} fue 1.07 veces.

Trapezio con $n = 10^{11}$ y $P = 24$: T_{sim}/T_{asim} fue 1.05 veces.

Trapezio con $n = 10^{11}$ y $P = 96$: T_{sim}/T_{asim} fue 0.97 veces.

5. Interpretación y límites

Una mejora de 1d-hier frente a 1d sería evidencia favorable a agrupar la difusión por nodo *en esta topología y versión*, pero no demuestra qué algoritmo usó la colectiva global internamente. La variante jerárquica todavía reserva una copia completa de B por proceso. Reducir esa memoria exigiría otra implementación, por ejemplo una ventana compartida por nodo.

La comparación 2D usa el mismo número de procesos que 1D en sus dos ramas, y controla la corrección con dos sumas de verificación. SUMMA realiza varios pasos de difusión de paneles y añade empaquetamiento; por eso se informa su tiempo completo además del tráfico. No debe extrapolarse directamente de 64 a 96 procesos. La optimización del núcleo aritmético, por ejemplo con una biblioteca BLAS, sería una pregunta separada; en la batería original de 96 procesos el cálculo ocupó una fracción muy pequeña del tiempo total.

En el trapecio, la ponderación supone que ciertos rangos corresponden a núcleos P y otros a núcleos E. Su utilidad debe interpretarse junto con la afinidad real registrada para cada corrida; una mejora de tiempo por sí sola no demuestra que la clasificación de núcleos fuera correcta.

Para $n = 10^8$, el tiempo interno de trapecio es de milisegundos. Su variación relativa puede ser grande, por lo que $n = 10^{11}$ es la comparación más informativa para el reparto de carga.

6. Reproducción

Desde esta carpeta:

- `./preparar.sh` compila los programas y copia los ejecutables al directorio temporal de cada nodo.
- `experimentos.py` ofrece `plan`, `smoke`, `run` y `extra`; los dos últimos guardan las baterías nuevas.
- `auditar_resultados.py` contrasta CSV y logs, y genera `SHA256SUMS`.
- `generar_informe_optimizacion.py` reconstruye este informe y su PDF desde los CSV, sin ejecutar MPI.
- `./ejecutar_todo.sh` reúne esos pasos.

El código, los scripts, las fuentes del informe, los CSV y los logs están en esta carpeta local. En los otros nodos solo se alojan temporalmente los ejecutables necesarios para `mpirun`.